MOTHER v122.20 — Benchmark de Latência e Desempenho

Run ID: `20260311_212337` **Data:** 2026-03-11 21:26:32 UTC **Metodologia:** Etalon Framework (arXiv:2407.07000) + NVIDIA NIM Benchmarking

---

1. Sumário Executivo

Métrica	MOTHER	GPT-4o API	Claude 3.5	Threshold OK
Disponibilidade	100.0%	99.9%	99.9%	≥99%
Error Rate	0.0%	0.1%	0.1%	≤1%
P50 (todas)	32330.7ms	3500ms	3000ms	<15000ms
P95 (todas)	41987.7ms	8000ms	7000ms	<30000ms
Cache Rate	16.7%	0%	0%	—

---

2. Latência por Complexidade de Query

Complexidade	N	P50 (ms)	P95 (ms)	P99 (ms)	Média (ms)	Std (ms)	TPS Est.	Cache
Simple	2	15309.6	28909.7	28909.7	15309.6	19233.4	71.4	50%
Medium	2	31116.3	35751.6	35751.6	31116.3	6555.2	14.8	0%
Complex	2	40042.8	41987.7	41987.7	40042.8	2750.5	21.2	0%

---

3. Comparação com Estado da Arte

Sistema	TTFT (ms)	E2E Simple	E2E Medium	E2E Complex	Fonte
MOTHER v122.20	N/A (streaming)	15309.6ms	31116.3ms	40042.8ms	Este estudo
GPT-4o API	650ms	2500ms	5000ms	12000ms	Artificial Analysis 2025
Claude 3.5 Sonnet	500ms	2000ms	4500ms	10000ms	Artificial Analysis 2025
Llama 3.1 70B (vLLM)	300ms	1500ms	3500ms	8000ms	NVIDIA NIM 2024
Threshold Aceitável	<2000ms	<5000ms	<15000ms	<60000ms	Wang et al. 2025 (BMC Psych)

> ***Nota:*** *MOTHER inclui pipeline CRAG v2 + Guardian + G-Eval, o que adiciona latência em troca de qualidade superior. Cache semântico reduz latência para queries repetidas (cache hit = resposta em <200ms).*

---

4. Distribuição de Latência (Histograma Textual)

```
0.0s-0.5s    |  (0)
0.5s-1.0s    |  (0)
1.0s-2.0s    | ▉ (1)
2.0s-5.0s    |  (0)
5.0s-10.0s   |  (0)
10.0s-30.0s  | ▉▉ (2)
>30.0s       | ▉▉▉ (3)
```

---

5. Impacto da Latência na Satisfação do Usuário

Latência	Percepção do Usuário	Satisfação Estimada	Fonte
<500ms	Instantâneo	Muito Alta	Nielsen (1993)
500ms-2s	Fluido	Alta	Nielsen (1993)
2s-5s	Perceptível	Média	Wang et al. 2025
5s-15s	Lento (com indicador)	Baixa-Média	Wang et al. 2025
>15s	Inaceitável (sem indicador)	Baixa	Wang et al. 2025

> ***Recomendação:*** *Para queries complexas (LFSA), implementar indicador de progresso e streaming para manter satisfação alta mesmo com E2E >15s. (Referência: arXiv:2407.07000, Etalon)*

---

6. Referências

#	Fonte	Relevância
[1]	Etalon (arXiv:2407.07000)	Framework de benchmark de latência LLM
[2]	NVIDIA NIM Benchmarking	Métricas TTFT/TBT/TPOT
[3]	Wang et al. 2025 (BMC Psychology)	Impacto da latência na satisfação
[4]	Artificial Analysis 2025	Benchmarks GPT-4o/Claude 3.5
[5]	Nielsen (1993)	Thresholds de resposta para UX

Gerado automaticamente pelo MOTHER Latency Benchmark v1.0 — 2026-03-11